



Apache Airflow – Orquestrando Workflows de Dados de Forma Eficiente

📅 junho 2, 2025 📁 Apache Airflow

Apache Airflow – Orquestrando Workflows de Dados de Forma Eficiente



Em projetos modernos de tecnologia, lidar com uma quantidade crescente de dados e

Busca

Busca

Categorias

- > Agentes de IA (45)
- > AgentOps (1)
- > AI Data Engineer (9)
- > AI Home Lab (1)
- > AI Software Engineer (4)

processos complexos tornou-se rotina. Ferramentas de orquestração de fluxos de trabalho como o Apache Airflow surgiram para auxiliar na coordenação dessas tarefas de maneira confiável e escalável.

Neste artigo vamos explorar o que é o Apache Airflow e por que ele tem se tornado uma peça-chave em projetos de dados. Abordaremos seus principais conceitos (como DAGs, agendamento e operadores), as características que o destacam, as vantagens de utilizá-lo, as limitações a considerar e exemplos de casos de uso no mundo dos negócios. Boa leitura.

O Que é o Apache Airflow?

Apache Airflow é uma plataforma open-source, escrita em Python, para orquestração de fluxos de trabalho (workflows) e pipelines de dados. Em termos simples, ele permite criar, agendar e monitorar sequências de tarefas de forma programática e visual.

Os fluxos de processos no Airflow são representados como grafos acíclicos dirigidos, os chamados DAGs (Directed Acyclic Graphs) – estruturas que mostram as tarefas como nós e as dependências entre elas como arestas. Cada DAG define uma ordem de execução das tarefas, garantindo que elas ocorram na sequência correta conforme suas dependências. Temos um curso inteiro sobre Airflow aqui na DSA: **Orquestração de Fluxos de Dados com Apache Airflow**.

O projeto foi criado originalmente no Airbnb em 2014 por Maxime Beauchemin para atender à necessidade de gerenciar workflows de dados cada vez mais complexos da empresa. Em 2016, ele foi incubado pela Apache Software Foundation e desde então evoluiu rapidamente, tornando-se um projeto Apache de nível superior e ganhando ampla adoção na comunidade. Hoje, o Airflow é conhecido por sua escalabilidade, flexibilidade e extensibilidade, sendo utilizado por empresas de diversos portes como a solução para

- > AIOps (1)
- > Airbyte (2)
- > Alta Disponibilidade (2)
- > Amazon EMR (1)
- > Análise de Dados (14)
- > Análise de Negócios (9)
- > Análise Exploratória de Dados (1)
- > Analista de Dados (9)
- > Analytics (53)
- > Analytics Engineer (8)
- > Apache Airflow (1)
- > Apache Beam (1)
- > Apache Doris (1)
- > Apache Hop (1)
- > Apache Kafka (1)
- > Apache NiFi (1)
- > Apache Spark (14)
- > APIs (1)
- > Aprendizado Contínuo (1)
- > Arquiteto de Dados (10)
- > Arquiteto de Soluções (1)
- > Arquiteto RPA (1)

orquestrar pipelines de dados de maneira robusta e customizável.

Principais Características do Airflow

Entre as funcionalidades e conceitos centrais do Apache Airflow, destacam-se os DAGs, o mecanismo de agendamento de tarefas, os operadores (tasks) e a extensibilidade da plataforma. A seguir, explicamos cada um desses pilares.

DAGs e Definição de Workflows

No Airflow, um DAG (Grafo Acíclico Dirigido) representa um workflow – isto é, um conjunto de tarefas interdependentes com uma ordem de execução definida. Cada tarefa é um passo atômico do processo (por exemplo, extrair dados de um banco, executar uma transformação ou treinar um modelo de Machine Learning) e as arestas entre as tarefas indicam precedência (qual tarefa depende da conclusão de outra). Por construção, um DAG não contém ciclos, garantindo que o fluxo de execução eventualmente termine. Uma grande vantagem desse modelo é a visualização clara do fluxo de trabalho. O Airflow fornece uma interface web que permite visualizar o DAG como um gráfico, facilitando entender a sequência de tarefas e o estado de cada uma. Em outras palavras, ao definir um pipeline no Airflow, você pode ver um diagrama do processo e acompanhar em tempo real quais tarefas já foram concluídas, quais estão em andamento ou pendentes. Essa visualização gráfica ajuda tanto no design do workflow quanto no monitoramento e depuração em caso de falhas.

Agendador de Tarefas (Scheduler)

Outro componente fundamental do Airflow é seu agendador de tarefas, conhecido simplesmente como Scheduler. O Scheduler é responsável por orquestrar a execução dos DAGs conforme regras definidas. Você pode configurar workflows para rodar em intervalos

› Arquitetura de Dados (36)

› Arquitetura Medalhão (5)

› Assistentes de Programação Agêntica (1)

› Atestado de Capacidade Técnica (1)

› Automação (4)

› Automação de Processos (2)

› AWS (Amazon Web Service) (2)

› Banco de Dados (9)

› Banco de Dados NoSQL (1)

› Bancos de Dados Vetoriais (3)

› Bibliografia (11)

› Big Data (33)

› BigQuery (1)

› Blockchain (8)

› Business (15)

› Business Analytics (1)

› Business Process Automation (BPA) (2)

› Cache Semântico (1)

regulares (por exemplo, diariamente à meia-noite, a cada hora, toda segunda-feira, etc.) ou acioná-los por gatilhos/eventos específicos. O agendador verifica periodicamente quais tarefas estão prontas para serem executadas (respeitando as dependências e horários agendados) e as envia para execução nos workers disponíveis. Graças a esse mecanismo, o Airflow consegue automatizar pipelines complexos, garantindo que cada etapa ocorra no momento certo e na ordem correta, sem necessidade de intervenção manual. O Airflow oferece flexibilidade de configuração de horário e frequência das execuções. É possível definir tanto cronogramas simples (por exemplo, “execute todo dia às 8:00”) quanto esquemas mais sofisticados, incluindo dependências em execuções anteriores ou em chegada de dados. A partir da versão 2.x, inclusive, o Airflow passou a suportar agendamentos baseados em datasets (conjuntos de dados), permitindo disparar DAGs automaticamente quando determinados datasets são atualizados. O Scheduler atua como o “cérebro” da orquestração, decidindo quando e onde cada tarefa será executada de acordo com o planejado.

Operadores e Tarefas (Operators & Tasks)

No Apache Airflow, as unidades de trabalho executáveis são chamadas de Tasks (tarefas), e cada tarefa é instanciada a partir de um Operator. Operadores são como “templates” que definem o que uma tarefa fará – por exemplo, existe o PythonOperator (que executa uma função Python), o BashOperator (que roda comandos Bash/scripts de shell), operadores especializados para transferir dados de/para bancos de dados (PostgresOperator, MySQLOperator, etc.), para interagir com serviços de nuvem (como GCSOperator do Google Cloud, S3Operator da AWS) e muitos outros. O Airflow vem com uma variedade de operadores built-in e a comunidade fornece muitos mais através de plugins, chamados de Providers (há providers para AWS, Google Cloud, Azure, Apache Spark, Slack, etc.). Cada tarefa dentro de um DAG é, portanto, uma instância de algum operador configurado com parâmetros específicos (por exemplo, um PythonOperator rodando certa função X ou um

> Câmara Semântica (1)

> Career Kit (1)

> Carreira (172)

> Casos de Uso (1)

> Certificação (2)

> Certificações Microsoft (1)

> ChatGPT (8)

> Cientista de Dados (19)

> Claude Code (1)

> Cloud Computing (15)

> Comparativo Técnico (2)

> Computação Quântica (1)

> Context Engineering (1)

> CRISP-DM (1)

> Curso Gratuito (11)

> Cyber Security (2)

> Cybersecurity (10)

> Dados Disponíveis Publicamente (2)

> Data Drift (5)

> Data Driven (1)

> Data Lake (3)

> Data Lakehouse (6)

BigQueryOperator executando uma query SQL Y). Os operadores proporcionam uma enorme capacidade de integração: é possível, sem muito esforço, conectar o workflow do Airflow com uma variedade de sistemas externos. Através dos chamados Hooks (ganchos de conexão) e operadores pré-existent, o Airflow se comunica com bancos de dados, APIs e serviços diversos sem que o desenvolvedor precise implementar do zero essas interações. Há dezenas de hooks prontos mantidos pelo projeto ou pela comunidade, permitindo ligação rápida a sistemas populares como MySQL, PostgreSQL, Oracle, HDFS, Amazon S3, Google BigQuery, Snowflake, Slack, etc. Isso torna o Airflow uma ferramenta muito útil para integração entre sistemas, funcionando como um hub central que coordena tarefas em diferentes plataformas. Vale destacar que o Airflow segue o conceito de “everything as code” – ou seja, tudo é definido em código Python. Os DAGs, tarefas e operadores são escritos em scripts Python, o que dá flexibilidade total ao desenvolvedor para adicionar lógica condicional, loops, gerar tarefas dinamicamente, ler configurações externas, entre outras possibilidades poderosas. Por exemplo, pode-se usar Python para gerar tarefas em massa conforme entradas de uma lista ou um arquivo, criando DAGs dinâmicos. Essa abordagem programática permite ajustar o workflow exatamente às necessidades e regras de negócio, diferentemente de ferramentas de ETL tradicionais com interface fixa. Em contrapartida, exige conhecimentos de programação para criar e manter os pipelines – um ponto que discutiremos nas limitações.

Extensibilidade e Plugins

A extensibilidade é outro ponto forte do Apache Airflow. A arquitetura do Airflow foi projetada para ser modular e plugável, de forma que usuários possam estender suas funcionalidades facilmente. Caso um tipo de operador ou integração que você precisa não exista nativamente, é possível desenvolver um operador personalizado em Python e incorporá-lo ao Airflow. O mesmo vale para hooks (conexões) e sensors (sensores que aguardam por alguma condição). Essa

- > Data Lineage (2)
- > Data Mining (1)
- > Data Observability (2)
- > Data Quality (2)
- > Data Science (214)
- > Data Science Academy (14)
- > Data Warehouse (3)
- > Database Administrator (3)
- > Database Analytics (1)
- > Database Engineer (1)
- > Databricks (9)
- > DataOps (6)
- > dbt (Data Build Tool) (2)
- > Deep Learning (11)
- > Delta Lake (1)
- > Deploy (2)
- > Desenvolvimento Pessoal (1)
- > Desenvolvimento Web (1)
- > Desvendando a Profissão (8)
- > DevOps (1)
- > Dia a Dia (7)

capacidade de extensão torna o Airflow adaptável a praticamente qualquer cenário de workflow. Além de criar novos operadores, o Airflow suporta a instalação de plugins que podem adicionar desde novas views na interface web até componentes totalmente novos. Muitas empresas e desenvolvedores contribuem com plugins open-source para expandir o Airflow – por exemplo, há plugins para facilitar envio de notificações, integração com ferramentas específicas ou para melhorar a observabilidade. Se o Airflow não faz algo por padrão, há grande chance de que alguém já tenha criado uma extensão para isso, ou de que você mesmo possa construir a sua. Essa filosofia extensível, aliada à grande comunidade ao redor do projeto, explica por que o Airflow consegue se adaptar a diversos casos de uso incomuns e evoluir junto com as necessidades de seus usuários.

Vantagens do Uso do Airflow

Por que usar o Apache Airflow? Abaixo listamos algumas das principais vantagens que tornaram o Airflow tão popular em projetos de dados e automação de workflows.

Baseado em Python (familiaridade e produtividade): O Airflow utiliza Python tanto em sua implementação quanto para definição dos workflows. Isso significa que equipes técnicas não precisam aprender uma linguagem proprietária ou interface nova – podem aproveitar a familiaridade com Python para escrever pipelines. A popularidade da Linguagem Python também garante um pool maior de talentos disponíveis e diversas bibliotecas de apoio. Construir DAGs em Python traz agilidade e baixa curva de adoção para quem já programa, aumentando a produtividade no desenvolvimento de workflows.

Flexibilidade e “tudo como código”: Como discutido, o Airflow permite definir workflows complexos inteiramente via código, oferecendo flexibilidade praticamente ilimitada. Podemos incorporar lógica personalizada, gerar tarefas dinamicamente e versionar pipelines junto com

> Docker (2)

> DuckDB (5)

> E-Books (6)

> E-books Técnicos DSA
(12)

> Econometria (1)

> Edge Computing (1)

> Engenharia Analítica (2)

> Engenharia de
Confiabilidade de Dados
(1)

> Engenharia de Dados
(45)

> Engenharia de Dados
Para IA (2)

> Engenharia de Software
(4)

> Engenharias (5)

> Engenheiro DataOps (4)

> Engenheiro de Dados
(15)

> Engenheiro de IA (13)

> Engenheiro de Machine
Learning (9)

> Estatística (8)

> ETL (5)

> Evaluation Driven
Development (1)

o código da aplicação. Essa abordagem traz controle total sobre o fluxo de trabalho e facilita ajustes para atender requisitos de negócio específicos. Workflows podem reagir a diferentes cenários, pular tarefas condicionalmente, repetir tentativas em caso de falha, entre outros – tudo configurável no código. Essa capacidade de personalização é uma vantagem enorme frente a ferramentas engessadas, tornando o Airflow aplicável a uma ampla variedade de problemas.

Escalabilidade e paralelismo: O Airflow foi concebido para rodar desde pequenos workflows até pipelines de produção de larga escala. Ele suporta a execução paralela de tarefas, aproveitando múltiplos workers para processar tarefas independentes simultaneamente dentro de um mesmo DAG (por exemplo, dezenas de tarefas em paralelo. Além disso, é possível distribuir a carga em mais de um Scheduler e múltiplos executores, configurando o Airflow para operar em cluster. Em ambientes com Celery Executor ou Kubernetes Executor, por exemplo, o Airflow consegue orquestrar centenas de tarefas concorrentes, escalando horizontalmente conforme a demanda. Essa capacidade de escalonamento permite que a ferramenta atenda às necessidades de negócios em crescimento, garantindo alto throughput de jobs e performance estável mesmo com muitos workflows agendados.

Integrações prontas e ecossistema rico: O Airflow se destaca pela grande quantidade de integrações nativas com outros sistemas. Graças aos diversos operadores e hooks disponíveis, ele se conecta facilmente a bancos de dados, frameworks de Big Data, serviços de cloud, APIs de SaaS e muito mais. Essa filosofia agiliza o desenvolvimento de pipelines, pois muitas tarefas comuns (como mover dados de um banco para o HDFS, ou disparar um job no Spark, ou enviar mensagem no Slack) já estão implementadas como módulos prontos. E quando não há algo disponível, podemos estender via plugins conforme mencionado. O Airflow atua como uma plataforma central de automação, integrando variadas ferramentas sem esforço excessivo. Essa extensibilidade e facilidade de integração economiza tempo de

> Eventos e Parcerias (2)

> Finanças e Engenharia Financeira (2)

> FinOps (1)

> Formações DSA (1)

> Forward Deployed Engineer (7)

> Generative AI Engineer (1)

> Gestão de Produtos (1)

> Git (1)

> Github (2)

> GitHub Actions (1)

> Governança de Dados (14)

> Guia de Carreira (13)

> Guia Definitivo (30)

> Hard Skills (1)

> Hardware (1)

> Harness Engineering (1)

> IA Aplicada ao Serviço Público (1)

> IA Generativa (5)

> IA Preditiva (1)

> Infraestrutura Como Código (IaC) (1)

desenvolvimento e torna o Airflow um componente versátil para orquestrar infraestruturas de dados heterogêneas.

Limitações e Desafios do Airflow

Apesar de todos os benefícios, é importante notar que o Apache Airflow não é uma bala de prata. Ele possui limitações e não é adequado para todos os cenários. Entre os principais desafios e pontos fracos da ferramenta, podemos citar estes abaixo.

Configuração e manutenção complexas: Colocar o Airflow em produção requer cuidar de diversos componentes (banco de metadados, scheduler, executors, workers, interface web) que precisam operar em harmonia. Em ambientes distribuídos, geralmente é necessário configurar e gerenciar um back-end de mensageria (como RabbitMQ ou Redis) para o Celery Executor ou orquestrar contêineres no Kubernetes, o que aumenta a complexidade de setup. A falta de documentação detalhada sobre deploy em larga escala agrava esse ponto, fazendo com que muitas empresas optem por contratar consultores ou usar serviços gerenciados (Cloud Composer do Google, Astronomer, etc.) para facilitar a implantação e escalonamento. Manter o Airflow escalável e altamente disponível pode demandar um esforço significativo de DevOps.

Não indicado para dados em tempo real: O Airflow foi projetado com foco em pipelines em batch, daqueles que têm início e fim definidos e rodam em intervalos programados (por exemplo, jobs diários ou horários). Não é uma ferramenta adequada para streaming contínuo de dados ou processamento em tempo real. Seu modelo de execução introduz latência (os workers pegam tarefas em ciclos agendados, geralmente de minuto em minuto) e não reage instantaneamente a eventos disparados a cada segundo. Portanto, tentar usar Airflow para fluxos near real-time ou orientados a evento não é recomendado. Há soluções mais apropriadas para streaming, como Apache Kafka, Apache Flink ou frameworks de

- › Inteligência Artificial (149)
- › Inteligência Artificial em Medicina (15)
- › Inteligência Artificial em Vendas (1)
- › Inteligência Artificial Explicável (XAI) (1)
- › Inteligência Artificial Generativa (22)
- › Inteligência Artificial no Direito (12)
- › Kaggle (1)
- › Kubernetes (1)
- › LangChain (6)
- › LangFlow (3)
- › LangGraph (4)
- › Large Data Models (1)
- › Large Language Models (LLMs) (23)
- › LGPD (1)
- › Linguagem Go (1)
- › Linguagem Julia (1)
- › Linguagem Python (20)
- › Linguagem R (4)
- › Linguagem Rust (1)
- › Linguagem Scala (1)

processamento de fluxo, que lidam melhor com dados em movimento e baixa latência. O Airflow pode complementar essas soluções em cenários híbridos – por exemplo, um pipeline de streaming escreve dados continuamente e o Airflow executa, a cada certo período, tarefas de agregação ou carga desses dados em lote. Mas é importante reconhecer que Airflow não foi feito para orquestrar processos 100% em tempo real.

Curva de aprendizado e necessidade de programação: Diferentemente de ferramentas de ETL que oferecem interfaces gráficas amigáveis ou abordagens low-code, o Airflow exige que os usuários tenham conhecimentos de desenvolvimento em Python e entendam vários conceitos técnicos (DAGs, tasks, operadores, XComs, etc.). Novatos podem achar a curva de aprendizado íngreme – é preciso assimilar muitas noções de agendamento, dependências e configuração antes de usar efetivamente a ferramenta. Além disso, montar pipelines complexos em código requer boas práticas de programação para manter a base de DAGs organizada e sustentável. Em equipes onde não há **Arquitetos de Dados** ou **Engenheiros de Dados** dedicados, essa barreira técnica pode dificultar a adoção. O Airflow não é muito acessível para profissionais não desenvolvedores, e mesmo para Arquitetos de Dados ou Engenheiros de Dados pode demandar tempo até dominar todos os detalhes de sua operacionalização.

(Outras limitações poderiam ser mencionadas, como ausência de versionamento nativo de DAGs, certa verbosidade na definição de pipelines e possíveis gargalos do Scheduler em cenários extremos. No entanto, os pontos acima representam os desafios mais comuns enfrentados ao utilizar o Airflow).

Casos de Uso Práticos no Mundo dos Negócios

Desde sua criação no Airbnb, o Apache Airflow vem sendo adotado em diversos setores de negócio para automatizar fluxos de trabalho de

- > Linguagem SQL (2)
- > LLM Distillation (1)
- > LLM Ensemble (1)
- > LLM Routing (1)
- > LLMOps (1)
- > Loop Engineering (1)
- > Machine Learning (64)
- > Machine Unlearning (1)
- > Marketing Digital (4)
- > Matemática (3)
- > Microsoft (7)
- > Microsoft Azure (1)
- > Microsoft Copilot (2)
- > Microsoft Excel (3)
- > Microsoft Fabric (5)
- > MinIO (1)
- > Mixture-of-Agents (MoA) (1)
- > MLOps (10)
- > Model Context Protocol (2)
- > Modelagem de Dados (2)
- > Modelagem Preditiva (1)
- > Modelos de Embeddings (1)

dados. Hoje, a ferramenta é utilizada por centenas de empresas globalmente, de startups a corporações, em aplicações variadas. Grandes nomes como Adobe, Airbnb, Etsy, Google, ING, Lyft, PayPal, Reddit, Square e X (Twitter) estão entre os usuários do Airflow em produção, aproveitando-o para orquestrar tarefas críticas de dados em escala. A seguir, listamos alguns casos de uso práticos onde o Airflow traz benefícios claros.

Migração e carga de dados: Orquestrar processos de ETL/ELT clássicos – extraíndo dados de sistemas de origem e carregando-os em um Data Lake, Data Warehouse (DW) ou plataforma na nuvem (como Snowflake, Amazon Redshift ou Google BigQuery) para posterior análise. Por exemplo, uma empresa de varejo pode usar o Airflow para, toda noite, extrair vendas do dia de diferentes bancos de dados e consolidá-las em um DW central. O Airflow gerencia as etapas de extração, transformação e carga garantindo que ocorram na ordem certa e registrando eventuais falhas para rerun.

Pipelines de Machine Learning (ML): Coordenação de workflows completos de **Ciência de Dados** e ML, incluindo preparação de dados, treinamento de modelos, validação e implantação. Com Airflow, é possível agendar o treinamento periódico de modelos (por exemplo, re-treinar um modelo de recomendação toda semana) e automatizar todas as etapas envolvidas. Empresas de tecnologia frequentemente usam Airflow para gerenciar pipelines de ML em produção, garantindo que dados estejam atualizados e que modelos sejam re-treinados/programados conforme necessário, tudo integrado a partir de uma só ferramenta.

Integração de dados de múltiplas fontes: Implementação de workflows complexos de integração onde dados de vários sistemas precisam ser combinados. O Airflow brilha ao orquestrar pipelines com muitas dependências e ramificações, por exemplo, coletando dados de APIs externas, bases SQL e arquivos, então aplicando transformações e unindo tudo em um formato unificado. Setores como o financeiro utilizam o Airflow para consolidar

> Modern Data Stack (2)

> MongoDB (1)

> n8n (4)

> Neo4j (1)

> Observabilidade (3)

> Ontologia (2)

> OpenRouter (1)

> Oracle (2)

> Oracle AI Database Engineer (1)

> Orquestração (2)

> Otimização de Hiperparâmetros (1)

> Padrão ReAct (Reason + Act) (1)

> Pipeline de Dados (3)

> Plataforma de Dados (5)

> Plataformas No-Code e Low-Code (8)

> Podcast (1)

> Por Onde Começar (9)

> Portfólio de Projetos (9)

> Pós-Graduação (41)

> Power BI (6)

> Processamento de Linguagem Natural (6)

informações de diferentes departamentos (cobrança, vendas, riscos) em um só pipeline de processamento noturno, facilitando a geração de relatórios integrados no dia seguinte.

Relatórios automatizados e BI: Geração automática de relatórios, dashboards e indicadores em bases recorrentes. Com Airflow, uma organização pode programar tarefas que calculam métricas e alimentam painéis de Business Intelligence diariamente ou mensalmente, sem intervenção manual. Por exemplo, um banco pode ter um DAG do Airflow que toda madrugada calcula indicadores de liquidez e risco e atualiza um dashboard executivo, ou uma empresa de mídia social pode compilar relatórios de engajamento dos usuários todo fim de semana. A confiabilidade do Airflow assegura que esses relatórios sejam produzidos no prazo e com os passos necessários (coleta de dados brutos, agregações, geração de PDFs, etc.) executados na sequência correta.

Tarefas de DevOps e infraestrutura: Automatização de rotinas operacionais e de TI. Além de dados, o Airflow pode orquestrar tarefas como backups de bancos de dados, limpeza de logs, verificações de sistemas e outras manutenções que precisem ocorrer de forma programada. Por exemplo, é possível configurar um DAG para efetuar backup completo de uma base de dados toda noite e armazená-lo em nuvem, ou para escalar recursos de um cluster em determinado horário e reduzi-los em outro. Empresas de software utilizam o Airflow para essas tarefas de suporte, garantindo que elas rodem regularmente e notificando responsáveis em caso de problemas. Dessa forma, o Airflow atua como um agendador corporativo geral, substituindo scripts isolados e oferecendo visibilidade centralizada dessas operações de backend.

Conclusão

O Apache Airflow consolidou-se como uma solução robusta e flexível para gestão de workflows de dados no ecossistema de tecnologia atual. Ele se mostra especialmente

- › Programação (2)
- › Project-Based Learning – PBL (1)
- › Prompt Engineering (4)
- › Python (5)
- › Redis (1)
- › Reinforcement Learning (1)
- › Responsible AI (2)
- › Retrieval-Augmented Generation (RAG) (11)
- › RPA (Robotic Process Automation) (18)
- › SAS (1)
- › Segurança (4)
- › Semantic Cache (1)
- › Séries Temporais (2)
- › Small Data (1)
- › Small Language Models (2)
- › Snowflake (2)
- › Soft Skills (5)
- › Spec-Driven Development (7)
- › SQL Server (3)
- › Storytelling (1)

útil para orquestrar pipelines de dados em lote (batch), tornando viável coordenar processos complexos de ETL, integrações e **Machine Learning** em ambientes de grande escala.

Por outro lado, como vimos, não é uma ferramenta sem restrições – há casos em que outra solução pode ser mais indicada (por exemplo, fluxos de dados streaming em tempo real ou situações em que não se deseja escrever código). Ainda assim, com todas as suas vantagens e limitações, o Airflow permanece uma das ferramentas mais adotadas para orquestração de workflows, contando com uma ampla comunidade e um histórico comprovado de uso em produção.

Para profissionais e empresas que lidam com múltiplos sistemas e pipelines de dados, o Airflow pode ser um grande aliado na automação e confiabilidade das operações, reduzindo trabalho manual e aumentando a eficiência dos processos de dados. Visite o site oficial da ferramenta: **Apache Airflow**.

Equipe DSA

> Streaming de Dados (1)

> Tecnologia (1)

> Tendências (4)

> TensorFlow (1)

> Terraform (1)

> Trabalho Remoto (1)

> Trilha de Aprendizagem (29)

> Vibe Coding (2)

> Visão Computacional (4)

> Visualização de Dados (4)

> Web 3.0 (1)

> Web Scraping (5)

✉ Inscrever-se ▼



Seja o Primeiro a Comentar!

B *I* U
{ } [+]

0 COMENTÁRIOS

© 2026 Data Science Academy

